

AgroBook Rural: Inclusão Digital e Estruturação de Dados na Agricultura Familiar através da Normalização Linguística

Gabriel Soares de Moraes Vitoriano dos Santos¹,
Pollyana Cássia de Sousa¹, Cleyton Vanut Cordeiro de Magalhães¹

¹Universidade Federal Rural de Pernambuco (UFRPE)
Bacharelado em Sistemas de Informação - DEINFO
Recife - PE - Brasil

`gabriel.vitoriano@ufrpe.br, pollyana.cassia@ufrpe.br, cleyton.vanut@ufrpe.br`

Abstract. *Family farming plays a vital socioeconomic role in Brazil; however, it faces severe barriers in production management due to low digital literacy and the inadequacy of market tools that rely on strictly technical language. This paper presents AgroBook Rural, a digital notebook designed as a social technology applied to agribusiness. The system mitigates “productive invisibility” by allowing farmers to log activities using their informal vocabulary and customary measurements (such as “sacks”, “buckets”, and “plots of land”). Through a data normalization layer, the software translates these informal inputs into structured data and compliance reports accepted by financial institutions and demanding buyers. In its third release, the system gained voice data entry with audio capture via `sounddevice`, transcription using Whisper (Groq), and semantic interpretation of northeastern Brazilian colloquial speech via the `llama-3.3-70b` language model, replacing the regex-based parser from the second release. The project focuses on the human transition from paper to digital, adapting the interface and data processing to the cognitive reality of farmers with low digital literacy.*

Resumo. *A agricultura familiar desempenha um papel socioeconômico vital no Brasil, contudo, enfrenta severas barreiras na gestão de sua produção devido à baixa digitalização e à inadequação das ferramentas de mercado, que utilizam linguagem estritamente técnica. Este trabalho apresenta o AgroBook Rural, um caderno digital projetado como tecnologia social aplicada ao agronegócio. O sistema mitiga a “invisibilidade produtiva” ao permitir que o agricultor realize registros utilizando seu vocabulário informal e medidas consuetudinárias (como “sacos”, “balde” e “pedaços de terra”). Através de uma camada de normalização de dados, o software traduz esses registros informais em dados estruturados e relatórios de conformidade aceitos por instituições financeiras e mercados compradores. Em sua terceira release, o sistema ganhou entrada de dados por voz com captura de áudio via `sounddevice`, transcrição pelo Whisper (Groq) e interpretação semântica da fala coloquial nordestina pelo modelo de linguagem `llama-3.3-70b`, substituindo o parser de expressões regulares da segunda release. O projeto foca na transição humana do papel para o digital, adaptando a interface e o processamento de dados à realidade cognitiva do produtor de baixa alfabetização digital.*

1. Contextualização e Delimitação do Problema Técnico-Social

O agronegócio consolidou-se como um dos principais motores econômicos do Brasil. No entanto, por trás das cifras da grande produção mecanizada, reside uma dualidade estrutural profunda: a coexistência entre latifúndios altamente tecnológicos e a agricultura familiar, que responde pela subsistência e pelo abastecimento do mercado interno, mas opera frequentemente à margem do desenvolvimento tecnológico. O acesso à tecnologia no campo apresenta desigualdades significativas no território nacional, evidenciando que a modernização da agricultura brasileira historicamente concentrou capitais e conhecimentos científicos em grandes propriedades, gerando processos excludentes para o pequeno produtor.

1.1. A Incompatibilidade Sociotécnica e a Invisibilidade Produtiva

Embora órgãos institucionais ofereçam modelos de cadernos de campo físicos em papel [Steding e Schmidt 2021], muitos produtores rurais não os utilizam devido à dificuldade prática de somar e cruzar dados manualmente, além do receio constante de perda física do documento. Por outro lado, observa-se uma alta penetração de smartphones no meio rural, impulsionada pelo uso massivo de ferramentas de comunicação instantânea como o WhatsApp para fins comerciais e pessoais [Amaral e Silva 2022]. É comum que o agricultor utilize o aplicativo para anotar informações diárias da produção de maneira fragmentada.

Essa dinâmica gera o problema central aqui abordado: a invisibilidade produtiva. O agricultor familiar produz com excelência, mas a desorganização de seus registros gera barreiras críticas: a impossibilidade de realizar uma gestão financeira real, a negação de financiamentos bancários essenciais, como o Programa Nacional de Fortalecimento da Agricultura Familiar (PRONAF), por falta de um histórico produtivo confiável, e a exclusão de mercados exigentes que demandam rastreabilidade comercial.

A raiz desse problema reside na arquitetura dos softwares de gestão agrícola de mercado, construídos sob uma lógica rígida de formulários técnicos que exigem métricas complexas. Esta exigência impõe uma barreira linguística e cognitiva excludente, gerando uma taxa expressiva de prevenção e rejeição aos sistemas tradicionais por parte do produtor de baixa digitalização [Santos 2023]. O diferencial inovador do AgroBook Rural diante do mercado consiste na inversão desse paradigma sociotécnico: em vez de exigir que o produtor rural aprenda a língua rígida do sistema, o AgroBook ensina o sistema a compreender o vocabulário e o cotidiano informal do agricultor, atuando como um tradutor adaptado à realidade humana e cognitiva do campo para promover real inclusão socioeconômica.

2. Análise Crítica do Ecossistema de Software Agrícola Atual

Para validar a originalidade e a necessidade de desenvolvimento do AgroBook Rural, realizou-se uma taxonomia de soluções tecnológicas voltadas ao campo, classificando-as em quatro vertentes operacionais complementares. Esta abordagem taxonômica expõe as lacunas que justificam a introdução de uma abordagem baseada em engenharia de software centrado no usuário de baixa digitalização [Santos 2023].

2.1. Taxonomia das Soluções Existentes no Mercado

Para validar a originalidade e a necessidade de desenvolvimento do AgroBook Rural, realizou-se uma taxonomia de soluções tecnológicas voltadas ao campo, classificando-as

em quatro vertentes operacionais complementares. Esta abordagem taxonômica expõe as lacunas que justificam a introdução de uma abordagem baseada em engenharia de software centrado no usuário de baixa digitalização [Santos 2023].

1. **Plataformas ERP de Larga Escala e Gestão Corporativa:** Softwares proprietários como o Aegro, Demetra e Granatum Agro oferecem robustez no processamento fiscal e contábil em propriedades de média e alta escala. No entanto, sua operação impõe taxas de licença proibitivas para economias familiares, além de interfaces que demandam profundo domínio de conceitos corporativos complexos, gerando barreira e exclusão operacional frente ao pequeno produtor [Santos 2023].
2. **Sistemas de Pesquisa Verticalizados e Monoculturais (Embrapa):** O catálogo de aplicativos móveis oficiais da Embrapa destaca-se pela precisão técnica, incluindo ferramentas como o Doutor Milho (monitoramento de safra específica), Custo Fácil (avicultura e suinocultura de corte integrada), Roda da Reprodução (parâmetros zootécnicos leiteiros) e Pasto Certo (manejo de pastagens). Contudo, a engenharia destas soluções assume um cenário de monocultura com assistência técnica regular. Na agricultura familiar tradicional, caracterizada pela policultura livre em lotes fragmentados, a necessidade de operar múltiplos aplicativos dispensos anula a viabilidade prática no dia a dia do campo [Steding e Schmidt 2021].
3. **Cadernos de Campo Eletrônicos de Rigidez Burocrática:** Soluções como a Planilha de Campo Digital (Embrapa Uva e Vinho) e sistemas de certificação internacional (ex: GlobalG.A.P. ou Veger) cumprem o papel de registrar dados para auditorias fitossanitárias [Steding e Schmidt 2021]. Estes sistemas exigem entrada manual rígida de jargões técnicos em matrizes eletrônicas. Como não convertem as informações em indicadores de gestão de ganho local para o produtor, enfrentam expressiva resistência e abandono após o período de fiscalização externa.
4. **Ferramentas Pragmáticas Informais de Uso Consuetudinário:** Na ausência de sistemas inclusivos, a pesquisa de campo identificou a adoção em massa de registros em cadernos de papel e o uso improvisado do WhatsApp para notas de safra fragmentadas [Amaral e Silva 2022]. Embora apresentem fricção cognitiva zero para o agricultor, estes mecanismos carecem de estruturação lógica, resultando na perda histórica de dados, impossibilidade de consolidação financeira e falta de validade legal ou bancária para a emissão de comprovação produtiva exigida por cooperativas e linhas de crédito rurais [Amaral e Silva 2022].

Para fundamentar estatisticamente o vazio sociotécnico que o AgroBook Rural se propõe a ocupar, estruturou-se uma matriz de conformidade de critérios de engenharia de software na Tabela 1.

Tabela 1. Matriz de Propriedades Técnico-Operacionais do Ecossistema de Softwares Agrícolas.

Categoria de Software	Foco Produtivo	Léxico Exigido	Modelo de Entrada	Perfil do Usuário
ERP Corporativo (Aegro)	Commodities	Contábil/Comercial	Formulário Rígido	Gestores Corporativos
Específicos Embrapa	Monocultura	Técnico/Veterinário	Inserção Numérica	Agrônomos/Técnicos
Cadernos Eletrônicos	Fiscal/Rastreio	Fitossanitário	Planilha Estruturada	Auditores Externos
Informalidade (WhatsApp)	Policultura Livre	Consuetudinário	Texto Livre/Áudio	Produtor Familiar
AgroBook Rural	Policultura Livre	Consuetudinário	Simplificado/Voz	Agricultor Inclusivo

3. Percurso Metodológico e Arquitetura Engenharia do Projeto

O desenvolvimento do AgroBook Rural baseia-se nos princípios de Sistemas de Informação aplicados à tecnologia social [Santos 2023], estruturado de maneira incremental para atender às avaliações continuadas da disciplina.

3.1. Ferramentas e Ambiente Interdisciplinar de Codificação

O ecossistema técnico do projeto foi selecionado para garantir a integridade da lógica de negócio, a separação de responsabilidades entre camadas e o controle ágil do histórico de alterações. O desenvolvimento utiliza:

- **Linguagem Base:** Python 3.11 para a estruturação do núcleo lógico de persistência, cálculo de conversão léxica e validações de regras de negócio.
- **Interface Gráfica:** PyQt6 para a construção da interface desktop, com layouts definidos em arquivos `.ui` criados no Qt Designer e carregados em tempo de execução via `uic.loadUi()`. A navegação entre as 15 telas do sistema é gerenciada por um `QStackedWidget`.
- **Autenticação por SMS:** Biblioteca Twilio para envio de código de verificação de 4 dígitos ao celular do agricultor durante o cadastro, com normalização automática do número para o formato E.164.
- **Entrada por Voz:** Bibliotecas `sounddevice` e `soundfile` para captura e gravação de áudio do microfone; API Whisper da Groq (`whisper-large-v3-turbo`) para transcrição em português; e modelo `llama-3.3-70b-versatile` para interpretação semântica da fala e extração de dados estruturados em JSON.
- **Gerenciamento de Credenciais:** `python-dotenv` para carregamento de variáveis de ambiente a partir de arquivo `.env`, mantendo as credenciais da API fora do código-fonte.
- **Persistência de Dados:** Arquivos JSON na pasta `data/`, com cada entidade (Farmer, Area, Planting, Harvest, Expense, CoOwners) responsável pela leitura e escrita de seu próprio arquivo.
- **Ambiente e Versionamento:** IDE Visual Studio Code (VS Code), com gestão de ramificações e versionamento via Git e hospedagem do repositório remoto na plataforma GitHub.

3.2. Cronograma de Implementação e Evolução do Sistema (VAs)

O cronograma operacional de Engenharia de Software foi mapeado em três grandes blocos de Verificação de Aprendizagem (VA), encontrando-se no seguinte estágio atual:

1. **Mapeamento e Validação Lógica (VA1 — Concluída):** Consolidação do mapeamento completo de requisitos lógicos, implementação dos CRUDs de área, plantio, colheita e gastos via interface terminal (CLI), validação matemática de CPF pelo algoritmo da Receita Federal, geração de relatório de safra em HTML, e estruturação do código em Programação Orientada a Objetos com separação em camadas `model/` e `utils/`.
2. **Arquitetura e Interface Gráfica (VA2 — Concluída):** Substituição completa da interface terminal por interface gráfica desktop construída com PyQt6; implementação de autenticação por código SMS via Twilio; desenvolvimento do

parser de linguagem natural para conversão de datas coloquiais (“ontem”, “há 3 dias”) e medidas agrícolas (“3 sacos” → 180 kg, “2 arrobas” → 30 kg); e adição do módulo de cadastro de multiproprietários e herdeiros com vínculo e percentual de participação.

3. **Acessibilidade Avançada por Voz e LLM (VA3 — Concluída):** Implementação do módulo completo de entrada de dados por voz, composto por quatro componentes: captura de áudio via `sounddevice` e transcrição pelo Whisper da Groq (`voice_input.py`); interpretação semântica da fala pelo modelo `llama-3.3-70b` com extração de dados estruturados em JSON (`llm_parser.py`); normalização de campos individuais de datas e medidas via LLM como substituto ao parser de regex da VA2 (`llm_normalizer.py`); e botão de microfone reutilizável com execução em `QThread` para não travar a interface (`voice_widget.py`). O módulo suporta desambiguação por contexto de tela e cobre variações coloquiais nordestinas não tratadas pelo regex anterior, como “ontonte”, “duas arroba e meia” e “oxxi é mio”.

4. Resultados Obtidos e Especificação de Requisitos Lógicos

Como resultado da consolidação integral das três etapas do projeto (VA1, VA2 e VA3), os requisitos do AgroBook Rural foram inteiramente implementados e validados, com a entrada por voz e interpretação via LLM completando o ciclo de inclusão sociotécnica proposto.

4.1. Mapeamento Funcional e Status Epistêmico dos Requisitos

Com base na matriz de acompanhamento e planejamento sistemático do grupo, as funcionalidades apresentam o seguinte status de evolução no presente estágio:

- **RF001 - Cadastro Perfilado do Agricultor (Status: Pronta — VA1):** Fluxo estruturado de entrada de dados de identificação (Celular, Nome, CPF, Cidade e Estado) com camadas prontas de validação de dados inválidos ou nulos.
- **RF002 - Gerenciamento de Área de Plantio (Status: Pronta — VA1):** Módulo para gerenciar os territórios agrícolas através de léxico afetivo local, validando a unicidade de nomes de áreas e detecção de dados inconsistentes.
- **RF003 - Registro Customizado de Safras (Status: Pronta — VA1):** Camada para entrada de dados de safras, associando cultura, área, quantidade inserida e data, contendo tratamentos para entradas numéricas inválidas.
- **RF004 - Balanço Operacional (Colheita e Custos) (Status: Pronta — VA1):** Controle de despesas de insumos e volumes colhidos em unidades customizáveis, com motor lógico para prevenção de valores negativos ou incoerentes.
- **RF005 - Emissão de Relatórios Estatísticos de Produtividade (Status: Pronta — VA1):** Compilação automatizada dos dados normalizados em formato de documento HTML estruturado para fins de exportação de dados de produção.
- **RF006 - Estruturação em POO (Status: Pronta — VA1):** Refatoração completa do sistema em classes com separação em camadas `model/`, `gui/` e `utils/`, onde cada entidade é responsável pela própria persistência e a classe `Farmer` agrega todas as demais.
- **RF007 - Interface Gráfica Desktop (Status: Pronta — VA2):** Substituição da interface terminal por aplicação desktop construída com PyQt6, com 15 telas navegáveis definidas em arquivos `.ui` e gerenciadas por `QStackedWidget`.

- **RF008 - Tratamento de Medidas na Linguagem do Agricultor via LLM (Status: Pronta — VA3):** Migração do parser de expressões regulares da VA2 para normalização via LLM (`llm_normalizer.py`), passando a cobrir variações coloquiais nordestinas antes não suportadas: datas como “ontonte” e “semana retrasada”, e medidas como “duas arroba e meia” e “cinco alqueire”. O valor original e o canônico continuam sendo armazenados simultaneamente.
- **RF009 - Cadastro de Multiproprietários e Herdeiros (Status: Pronta — VA2):** Módulo para registro de coproprietários com vínculos específicos (Proprietário principal, Coproprietário, Herdeiro, Meeiro, Arrendatário) e percentual de participação, com validação matemática de CPF. Na VA3 ganhou suporte a cadastro por voz com contexto específico.
- **RF010 - Envio de Código por SMS (Status: Pronta — VA2):** Autenticação no cadastro via código de 4 dígitos enviado ao celular do agricultor através da API Twilio, com normalização automática do número para o formato E.164.
- **RF011 - Captura e Transcrição de Voz (Status: Pronta — VA3):** Gravação de áudio via `sounddevice` (16 kHz), envio para o modelo `whisper-large-v3-turbo` da Groq com idioma português e retorno do texto transcrito. Suporta sotaque nordestino e vocabulário do campo.
- **RF012 - Interpretação Semântica da Fala via LLM (Status: Pronta — VA3):** O texto transcrito pelo Whisper é enviado ao modelo `llama-3.3-70b-versatile` com prompt estruturado que classifica o tipo da fala (plantio, colheita, gasto, nome, CPF, cidade, coproprietário) e extrai os campos correspondentes em JSON.
- **RF013 - Desambiguação por Contexto de Tela (Status: Pronta — VA3):** A função `parse_fala_contexto()` envia ao LLM o contexto da tela atual junto com a fala, permitindo classificação correta mesmo sem verbo explícito (ex: “dez sacos de milho” na tela de colheita é interpretado como colheita).
- **RF014 - Botão de Microfone Reutilizável (Status: Pronta — VA3):** Componente `voice_widget.py` com `make_mic_button()` e `attach_voice_to_lineedit()` que encapsula todo o fluxo de voz. A gravação e as chamadas à API rodam em `QThread` separada com feedback visual em tempo real (botão muda de verde para vermelho durante a gravação).
- **RF015 - Normalização de Medidas e Datas via LLM (Status: Pronta — VA3):** Módulo `llm_normalizer.py` que recebe campos individuais digitados ou falados e os envia ao LLM com prompts específicos (`DATE_PROMPT` ou `AMOUNT_PROMPT`). Converte expressões como “uns três saco” para “180.0 kg” e “ontonte” para `dd/mm/yyyy`. Quando o campo já está no formato correto, o LLM não é chamado. O valor original e o canônico são exibidos e salvos simultaneamente no registro.

4.2. Comparativo de Cobertura Linguística: VA2 (Regex) versus VA3 (LLM)

A substituição do parser de expressões regulares pelo modelo de linguagem `llama-3.3-70b` representa o principal avanço técnico da VA3. A Tabela 3 ilustra a expansão de cobertura para variações coloquiais nordestinas.

Tabela 2. Cobertura linguística do parser de datas e medidas: VA2 vs. VA3.

Entrada do agricultor	VA2 (Regex)	VA3 (LLM)
“ontem”		
“ontonte”	×	(2 dias atrás)
“faz uns três dias”	×	(3 dias atrás)
“3 sacos”	(180 kg)	(180 kg)
“duas arroba e meia”	×	(37,5 kg)
“oxxi é mio”	×	(milho)

4.3. Representação Visual do Modelo Logístico do Sistema

O fluxo operacional de entrada de dados, validação de exceções e normalização linguística projetado para a arquitetura básica do AgroBook Rural está ilustrado através da estrutura visual da Figura 1.



Figura 1. Identidade Visual integrada ao formato de coluna única da SBC.

As dimensões sociais afetadas pela transição que o AgroBook Rural propõe na rotina produtiva da agricultura familiar estão sintetizadas na Tabela 2.

Tabela 3. Impactos da Transição Operacional com o AgroBook Rural.

Dimensão	Cenário Informal Tradicional	Cenário com AgroBook
Gestão Financeira	Desconhecimento do lucro real	Margem de lucro automatizada
Acesso a Crédito	Negativa bancária por falta de prova	Histórico via Relatório aceito
Comercialização	Exclusão por falta de rastreabilidade	Origem comprovada da safra
Linguagem Digital	Rejeição a formulários rígidos	Léxico local e registro por voz

5. Considerações Finais e Direccionamentos Futuros

O AgroBook Rural cumpre o papel fundamental de preencher uma lacuna histórica no desenvolvimento de softwares voltados ao agronegócio brasileiro. Ao focar na transição humana e respeitar a identidade linguística do pequeno produtor, o projeto prova que é possível aliar a engenharia de software com o impacto social direto. Ao converter simples anotações informais em chaves de acesso a direitos econômicos, crédito rural e mercados

sustentáveis, a ferramenta promove autonomia, dignidade e real inclusão digital para a agricultura familiar.

A terceira release concluiu o ciclo de inclusão sociotécnica proposto pelo projeto, entregando o módulo completo de entrada por voz: captura de áudio, transcrição pelo Whisper e interpretação semântica da fala coloquial nordestina via LLM. A substituição do parser de regex pelo modelo `llama-3.3-70b` eliminou as limitações de padrões fixos, permitindo que o sistema compreenda qualquer variação linguística do campo sem necessidade de reprogramação. Como perspectiva de evolução futura, o sistema pode ser expandido com testes de usabilidade em campo com agricultores reais, integração com plataformas de crédito rural e geração de relatórios no formato exigido pelo PRONAF.

6. Agradecimentos

Os autores agradecem à Universidade Federal Rural de Pernambuco (UFRPE) pelo apoio institucional no desenvolvimento deste projeto interdisciplinar, e ao orientador Prof. Dr. Cleyton Vanut Cordeiro de Magalhães pelas valiosas contribuições teóricas e técnicas dedicadas a esta pesquisa.

Referências

Amaral, J. R. e Silva, M. T. (2022). Uso de aplicativos de mensageria instantânea como ferramenta de gestão informal na agricultura familiar. In Anais do Simpósio Brasileiro de Informática na Agropecuária (SBIAgro), pages 112-121. SBC.

Santos, F. A. (2023). Tecnologias Sociais e Inclusão Digital no Brasil: Engenharia de Software Centrada no Usuário. Editora Universitária da UFRPE, Recife, Brasil.

Steding, G. e Schmidt, A. (2021). A digitalização no campo: Desafios do pequeno produtor rural na transição do papel para o smartphone. Revista Brasileira de Agrocomputação, 11(2):45-58.